Jakie praktyki korelują z jakością PR-ów tworzonych przez agentów?

Krótki raport do repozytorium **github.com/glowacz/pb** · projekt badawczy, Uniwersytet Warszawski

1. Cel i dane

Projekt analizuje zbiór **AIDev-pop** – ok. 33,6 tys. pull requestów napisanych przez agentów AI (OpenAI Codex, Copilot, Devin, Cursor, Claude Code). Pytanie badawcze: *które praktyki – rozmiar PR-a, typ zadania, granularność commitów – wiążą się z jakością PR-ów agentowych?*

Dane zostały zebrane w jednej, zdenormalizowanej tabeli (**aidev_pop_pr_features.parquet**, tworzona w **create_parquet.ipynb**). Cała analiza znajduje się w **analysis.ipynb**, a wyniki liczbowe i wykresy w katalogu **analysis_outputs/**.

2. Zmienne

Praktyki (zmienne niezależne)	Wskaźniki jakości (zmienne zależne)
Rozmiar PR-a: dodane / usunięte / zmienione linie, liczba plików Granularność commitów: liczba, średni i maks. rozmiar commita Typ zadania: kategoria Conventional Commit (feat, fix, docs, ...) Opis: długość tytułu i treści, powiązanie z issue	Czy PR został zmergowany Czas do zmergowania Liczba komentarzy inline w review Liczba żądanych zmian (*changes requested*)

3. Metody

Metoda	Wynik	Zastosowanie
Korelacja Spearmana	ρ	Surowy, jednowymiarowy związek monotoniczny (bez kontroli)
Regresja logistyczna	iloraz szans (OR)	Szansa zmergowania, z kontrolą pozostałych zmiennych
Model Coxa (PH)	hazard ratio (HR)	Szybkość mergowania (HR > 1 = szybciej); uwzględnia cenzurowanie otwartych PR-ów
Ujemna dwumianowa (NB)	IRR	Dane licznikowe (komentarze, żądane zmiany); radzi sobie z naddyspersją

Kluczowe decyzje przy przygotowaniu danych:

- transformacja **log1p** skośnych predyktorów (linie, pliki, commity, długości, gwiazdki repo) – rozkłady mają ciężkie ogony;
- **kontrole**: agent, log(gwiazdki repo), język repozytorium;
- **błędy standardowe klastrowane** na poziomie repozytorium (PR-y z jednego repo nie są niezależne);
- rzadkie typy zadań i języki łączone w kategorię „other”.

4. Najważniejsze wyniki

Obszar	Wynik (po kontroli pozostałych zmiennych)
Granularność commitów (więcej commitów)	Wyższa szansa mergowania (OR ≈ 1,67), ale znacznie więcej uwagi w review: komentarze inline IRR ≈ 3,7, żądane zmiany IRR ≈ 2,8; merge trwa dłużej (HR ≈ 0,76). Surowa korelacja jest odwrotna (ρ = −0,23 z mergowaniem) – dobry przykład, po co modele wielowymiarowe.
Rozmiar PR-a (więcej dodanych linii)	Niższa szansa mergowania (OR ≈ 0,79), wolniejszy merge (HR ≈ 0,91), więcej komentarzy (IRR ≈ 1,31) i żądanych zmian (IRR ≈ 1,38). Rozłożenie zmian na więcej plików zmniejsza liczbę żądanych zmian (IRR ≈ 0,82).
Typ zadania	Wskaźnik mergowania: docs 0,84; fix/feat ok. 0,65–0,71; perf 0,55; other 0,32. W modelu docs ma najwyższą szansę mergowania, a perf, fix i feat niższą (względem build).
Powiązanie z issue	Brak wpływu na szansę mergowania (OR ≈ 1,01, nieistotne); wolniejszy merge (HR ≈ 0,79) i więcej komentarzy (IRR ≈ 1,42) – prawdopodobnie znacznik trudniejszych zadań.
Agent	Największe różnice: Codex – 83% zmergowanych (n ≈ 21,8 tys., mediana 1 commit, 74 zmienione linie); Copilot – 43% i wielokrotnie więcej żądanych zmian (IRR ≈ 7,2 vs baza); Devin IRR ≈ 3,3.

5. Wnioski

- Mniejsze PR-y są mergowane częściej i szybciej.
- Bardziej rozdrobnione commity zwiększają szansę akceptacji, kosztem dłuższego i bardziej wymagającego review.
- PR-y typu docs są akceptowane najchętniej, fix i perf najrzadziej.
- Powiązanie z issue samo w sobie nie gwarantuje jakości.
- Niska wartość Cramér's V dla typu zadania (0,14) nie oznacza, że typ jest nieistotny – w regresji efekt docs vs perf jest realny i istotny.

6. Struktura repozytorium

Plik / katalog	Zawartość
analysis.ipynb	Pełna analiza (modele, statystyki, wykresy)
create_parquet.ipynb	Budowa zdenormalizowanej tabeli cech PR-ów
aidev_pop_pr_features.parquet	Tabela wejściowa do analizy
analysis_outputs/	logit_merged.csv, cox_time_to_merge.csv, negbin_inline_cmts_glm.csv, negbin_changes_requested.csv, bivariate_spearman.csv, summary_by_agent.csv, merge_rate_by_task_type.csv, figs/

Uwaga: raport streszcza opis projektu z pliku README repozytorium (stan na 15.10.2026; 10 commitów, gałąź main). Wartości liczbowe pochodzą z README – nie były ponownie wyliczane na podstawie notebooków ani danych.